

Recomendador de Disciplinas com Busca Semântica (SBERT), Filtros Estruturais e Balanceamento de Carga Curricular

André Rezende Gabriel Ramos Victor Hugo Vitor Archanjo

Fundamentos de Inteligência Artificial
Universidade Federal de Minas Gerais

26 de junho de 2026

Resumo

Este relatório apresenta um sistema de recomendação de disciplinas para o curso de Engenharia de Sistemas da UFMG, desenvolvido como Trabalho Prático III da disciplina Fundamentos de Inteligência Artificial. O sistema integra busca semântica com Sentence-BERT (modelo BERTimbau), classificador BERT com fine-tuning progressivo em três estágios, e filtros estruturais determinísticos para pré-requisitos, balanceamento de dificuldade e prevenção de conflitos de horário. A base de dados compreende 76 disciplinas com ementas do site GEES UFMG, horários da grade oficial e métricas de dificuldade de uma planilha colaborativa estudantil. Os resultados demonstram que a arquitetura híbrida é essencial: o SBERT isolado atinge Precision@10 de apenas 2,86%, pois ranqueia exclusivamente por afinidade semântica sem conhecer a estrutura curricular; com a aplicação dos filtros estruturais, a recomendação final atinge 100% de aderência às regras do PPC. Uma interface interativa em Streamlit complementa o sistema, permitindo que alunos explorem recomendações em tempo real.

1 Introdução

Com a crescente flexibilidade curricular na educação superior, estudantes enfrentam o desafio de compor planos de estudo semestrais otimizados. No curso de Engenharia de Sistemas da UFMG, são 76 disciplinas disponíveis, com pré-requisitos encadeados, horários distribuídos em diferentes turnos e níveis de dificuldade variados — fatores que, isoladamente, já tornam a decisão complexa. Decisões baseadas apenas no nome da disciplina ou em uma leitura superficial da ementa podem resultar em semestres sobrecarregados ou desconexos do percurso desejado pelo aluno.

Neste contexto, técnicas de Processamento de Linguagem Natural (NLP) e Transfer Learning oferecem uma oportunidade de aproximar a recomendação acadêmica da compreensão semântica dos interesses do estudante. Modelos pré-treinados como o BERT [1],

e sua variante para o português brasileiro, o BERTimbau [3], permitem codificar textos em vetores densos que capturam similaridade semântica entre conceitos. Com a adaptação via Sentence-BERT [2], é possível gerar embeddings de tamanho fixo adequados para busca por similaridade de cosseno, viabilizando o ranqueamento de disciplinas por afinidade temática com o perfil do aluno.

Este trabalho propõe um motor de recomendação que combina **Transfer Learning** sobre o BERTimbau com filtros estruturais rigorosos. O sistema opera em dois níveis complementares: (1) ranqueamento semântico das disciplinas por similaridade de cosseno entre o perfil do aluno e as ementas, via Sentence-BERT; e (2) aplicação sequencial de regras de pré-requisitos, orçamento de dificuldade e compatibilidade de horários, garantindo a viabilidade acadêmica das recomendações.

2 Objetivos

O objetivo geral deste trabalho é desenvolver um sistema de recomendação de disciplinas que una compreensão semântica em português brasileiro com o rigor das restrições acadêmicas do Projeto Pedagógico do Curso (PPC) de Engenharia de Sistemas da UFMG.

Os objetivos específicos são:

1. Construir uma base de dados unificada integrando ementas, horários, dificuldade e pré-requisitos das 76 disciplinas do curso;
2. Implementar busca semântica com Sentence-BERT (BERTimbau) para ranquear disciplinas por similaridade de cosseno com o perfil do aluno;
3. Desenvolver filtros estruturais determinísticos para validação de pré-requisitos, balanceamento de dificuldade e prevenção de conflitos de horário;
4. Realizar fine-tuning progressivo de um classificador BERT em três estágios (Feature Extraction, Partial Unfreeze, Full Fine-Tuning);
5. Avaliar o sistema com métricas quantitativas (Precision@k, Recall@k, MRR, Acurácia, F1) e com cenários qualitativos simulados;
6. Disponibilizar uma interface interativa para demonstração do sistema com Streamlit.

3 Base de Dados e Curadoria

A construção da base de dados foi uma etapa crítica do projeto, pois não existia um dataset unificado com todas as informações necessárias para a recomendação. Foram integradas quatro fontes distintas de dados.

3.1 Fontes de dados

1. **Mapa de Oferta (2026/1):** documento oficial do colegiado com 76 disciplinas da grade curricular de Engenharia de Sistemas, contendo códigos, nomes, carga horária, natureza (obrigatória/optativa) e período sugerido. Fonte: grade curricular do GEES UFMG [6] e estrutura curricular oficial do curso [7].

2. **Ementas (GEES UFMG):** 52 ementas detalhadas obtidas do site `geesufmg.com` por web scraping; as 24 restantes receberam descrições genéricas inferidas a partir do nome da disciplina (ex.: “Disciplina de Introdução à Robótica”).
3. **Grade Horária:** planilha oficial com 41 disciplinas contendo dia da semana e turno, disponibilizada pelo departamento [8]; 17 códigos placeholder foram mapeados manualmente para códigos reais do PPC.
4. **Dificuldade Percebida:** planilha colaborativa preenchida por estudantes com avaliações de “Dificuldade” e “Trabalho” em escala de 1 a 10, cobrindo 50 das 76 disciplinas. A métrica utilizada (W_d) é a média das duas dimensões.

A documentação completa do Projeto Pedagógico do Curso (PPC) de Engenharia de Sistemas está disponível no drive do colegiado [9].

3.2 Análise exploratória

A Tabela 1 apresenta a cobertura das fontes de dados. Das 76 disciplinas, 100% possuem ementa (52 detalhadas e 24 inferidas), 54% possuem grade horária e 66% possuem score de dificuldade. Esta cobertura parcial é uma limitação realista: disciplinas sem horário não são ofertadas no semestre corrente; disciplinas sem dificuldade recebem peso neutro no balanceamento.

Table 1: Cobertura das fontes de dados

Fonte	Qtde.	%
Total de disciplinas	76	100%
Ementa detalhada (GEES)	52	68%
Ementa inferida (genérica)	24	32%
Com grade horária	41	54%
Com score de dificuldade	50	66%
Com pré-requisitos	31	41%

A distribuição por área de conhecimento (Tabela 2) revela a predominância de disciplinas de Engenharia Elétrica e Sistemas (40), seguidas por Engenharia Mecânica/Aeroespacial (7), Matemática (6) e Computação (5). As 15 áreas restantes possuem entre 1 e 3 disciplinas cada. Esta concentração impõe desafios para a busca semântica: ementas de áreas próximas (como “Controle” e “Automação”) tendem a produzir embeddings similares, reduzindo a discriminação do ranqueamento.

Table 2: Distribuição de disciplinas por área de conhecimento


Área de Conhecimento	Qtde.
Engenharia Elétrica e Sistemas	40
Engenharia Mecânica/Aeroespacial	7
Matemática	6
Computação	5
Engenharia de Produção	3
Física	3
Engenharia (Tópicos Especiais)	3
Materiais	2
Química / Estatística / Economia	3
Outras (4 áreas)	4

3.3 Modelagem das disciplinas

Cada disciplina d é modelada como uma tupla contendo: código, nome, ementa (E_d), período sugerido, pré-requisitos (R_d), score de dificuldade geral ($W_d \in [1, 10]$), e slots de horário ($H_d = \{(dia_i, turno_i)\}$). Esta estrutura permite que o recomendador opere tanto no espaço semântico (comparando E_d com o perfil do aluno) quanto no espaço de restrições (verificando R_d e H_d).

4 Metodologia

A arquitetura do sistema segue um pipeline de cinco etapas. As três primeiras operam no espaço semântico via Transfer Learning com BERTimbau; as duas últimas aplicam regras determinísticas da estrutura curricular:



4.1 Busca semântica com Sentence-BERT

Utilizou-se o modelo `neuralmind/bert-base-portuguese-cased`, pré-treinado em 2,7 bilhões de tokens de texto em português (Wikipedia PT + BrWaC), adaptado via Sentence-BERT [2] para gerar embeddings de tamanho fixo (768 dimensões). O SBERT foi escolhido em detrimento do BERT base por duas razões: (1) produz embeddings semanticamente significativos sem necessidade de uma tarefa de classificação auxiliar; e (2) permite busca por similaridade de cosseno em tempo constante após a codificação do corpus.

O corpus é composto pelas ementas enriquecidas com nome da disciplina e área de conhecimento. A similaridade entre o perfil textual do estudante (q) e cada disciplina candidata (d) é calculada pela similaridade de cosseno:

$$\text{Sim}(q, d) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|} \quad (1)$$

Onde $\mathbf{q}$ e $\mathbf{d}$ são os embeddings 768-d do perfil e da ementa, respectivamente. O resultado é um ranqueamento das 76 disciplinas, do qual são selecionadas as top-20 para a etapa de filtros.

4.2 Filtros estruturais

Após o ranqueamento semântico, três filtros determinísticos são aplicados sequencialmente para garantir a viabilidade acadêmica da recomendação:

1. **Pré-requisitos:** uma disciplina d é aceita se e somente se $R_d \subseteq C$, onde C é o conjunto de disciplinas já cursadas pelo aluno. Disciplinas sem pré-requisitos são sempre aceitas neste filtro.
2. **Balanceamento guloso por dificuldade:** as disciplinas válidas são selecionadas em ordem decrescente de score semântico e crescente de dificuldade, até que $\sum W_d$ atinja o orçamento máximo do semestre (padrão: 22). O algoritmo guloso garante uma solução viável em tempo $O(n \log n)$.
3. **Conflito de horários:** durante a seleção gulosa, uma disciplina é descartada se qualquer um de seus slots (*dia, turno*) já estiver ocupado por uma disciplina previamente selecionada. Disciplinas sem horário definido são aceitas (não geram conflito).

Esta arquitetura híbrida é a principal contribuição do trabalho: o SBERT captura a dimensão subjetiva e semântica dos interesses do aluno, enquanto as regras estruturais conferem o rigor necessário para que a recomendação seja academicamente viável. Sem o SBERT, o recomendador seria uma simples verificação de regras; sem os filtros, o recomendador produziria sugestões semanticamente coerentes mas academicamente inviáveis.

4.3 Fine-tuning do BERT classificador

Além da busca semântica, treinou-se um classificador binário BERT para decidir se uma disciplina candidata é adequada ao perfil do estudante (label 1 = relevante, 0 = irrelevante). A entrada do modelo utiliza pares de sentenças no formato `[CLS] perfil_texto [SEP] candidate_text [SEP]`, análogo à tarefa de similaridade textual para a qual o BERT foi originalmente pré-treinado.

O treinamento utilizou **Transfer Learning progressivo em três estágios**, estratégia particularmente adequada para datasets pequenos como o nosso (357 exemplos de treino), prevenindo o overfitting que ocorreria com fine-tuning completo desde a primeira época:

1. **Estágio 1 — Feature Extraction** ($lr = 5 \times 10^{-5}$): apenas a cabeça de classificação (uma camada linear sobre o token `[CLS]`) é treinada, com o encoder BERT inteiramente congelado.
2. **Estágio 2 — Partial Unfreeze** ($lr = 3 \times 10^{-5}$): as duas últimas camadas do encoder Transformer são descongeladas, permitindo ajuste fino das representações de mais alto nível.
3. **Estágio 3 — Full Fine-Tuning** ($lr = 2 \times 10^{-5}$): o modelo inteiro é ajustado com learning rate reduzido para refinar todas as camadas sem causar *catastrophic forgetting*.

O otimizador AdamW foi utilizado com agendador linear com warmup (10% dos passos).

4.4 Geração de dados sintéticos

Os pares de treino foram gerados sinteticamente a partir de 10 perfis de estudante. Cada perfil é construído como um prefixo acumulativo dos períodos: o perfil do p -ésimo período contém todas as disciplinas até o período p . A partir desses perfis base, variantes com optativas são geradas.

Para cada par (perfil, disciplina candidata), um label binário é atribuído deterministicamente pelas regras do PPC:

$$\text{label}(p, d) = \begin{cases} 1, & \text{se } R_d \subseteq C_p \text{ e } (d \in \text{grupo_optativa}(C_p) \text{ ou } \text{perodo}(d) \leq \max_perodo(C_p) + 1) \\ 0, & \text{caso contrário} \end{cases} \quad (2)$$

Esta abordagem resultou em 357 pares de treino, 51 de validação e 100 de teste. O desbalanceamento é severo: apenas 6,4% dos pares são positivos, refletindo a realidade de que a maioria das disciplinas não é adequada para um dado perfil de aluno.

4.5 Baseline estrutural

Um baseline de Regressão Logística foi treinado sobre três features puramente estruturais: (1) pré-requisitos satisfeitos (booleana); (2) mesmo trilha de optativa (booleana); e (3) período seguinte ao máximo concluído (booleana). Este baseline não utiliza nenhuma informação semântica das ementas — apenas as regras do PPC. Seu propósito é servir como *sanity check*: se o baseline atingir 100% de acurácia, confirma-se que os labels foram gerados corretamente e que a tarefa é estruturalmente determinística.

5 Configuração Experimental

O modelo Sentence-BERT foi carregado do Hugging Face Hub (`neuralmind/bert-base-portuguese`) sem fine-tuning adicional para a tarefa de busca semântica. Os embeddings do corpus de 76 disciplinas são gerados uma única vez e armazenados em memória, permitindo busca em tempo de inferência inferior a 100 ms.

Para o classificador BERT, foram executados 3 estágios progressivos com 1 época cada, batch size de 8, e learning rates de 5×10^{-5} , 3×10^{-5} e 2×10^{-5} respectivamente. O treinamento foi realizado em GPU T4 via Google Colab. As métricas de avaliação incluem acurácia e F1-score para o classificador, e Precision@10, Recall@10 e MRR (Mean Reciprocal Rank) para a busca semântica.

Para validação qualitativa, foram simulados 6 cenários de recomendação: calouro (1º período), meio de curso com foco em IA, busca de optativa livre, disciplina complementar a um trilha específico, reta final do curso, e perfil generalista sem preferência declarada. Em cada cenário, verificou-se a aderência às regras do PPC e a coerência semântica das recomendações.

6 Resultados

6.1 Métricas de classificação

A Tabela 3 apresenta as métricas de avaliação do sistema. O baseline de regressão logística atingiu 100% de acurácia e F1, confirmando a corretude da geração dos labels sintéticos. O BERT fine-tuned, por sua vez, atingiu 89% de acurácia mas F1 de 0,00 — resultado que evidencia o impacto do desbalanceamento severo dos dados.

Table 3: Métricas de avaliação do sistema

Métrica	Valor
<i>Estatísticas da base de dados</i>	
Disciplinas na base	76
Ementas detalhadas (GEES)	52
Disciplinas com horário	41
Disciplinas com dificuldade	50
Perfis sintéticos gerados	10
Pares de treino (classif.)	357
Positivos no treino	6,4%
<i>Classificação binária</i>	
Baseline (Reg. Logística) — Acurácia	1,0000
Baseline (Reg. Logística) — F1	1,0000
BERT fine-tuned — Acurácia	0,89
BERT fine-tuned — F1	0,00
<i>Busca semântica</i>	
SBERT — Precision@10	0,0286
SBERT — Recall@10	0,0680
SBERT — MRR	0,0762
<i>Recomendação final (híbrida)</i>	
Aderência às regras do PPC	1,0000
Conflitos de horário	0

6.2 Métricas de busca semântica

O SBERT atingiu Precision@10 de 2,86% e MRR de 0,076. O baixo desempenho em métricas de recuperação é esperado e não indica falha do modelo de embeddings. Pelo contrário, ele demonstra precisamente por que a busca puramente semântica é inadequada para recomendação de disciplinas: o SBERT rankeia corretamente disciplinas por afinidade temática (ex.: uma consulta sobre “IA” retorna disciplinas de Computação e Estatística com alta similaridade), mas essas disciplinas frequentemente possuem pré-requisitos não atendidos ou pertencem a períodos muito distantes na grade.

6.3 Cenários simulados

Nos 6 cenários simulados, após a aplicação dos três filtros estruturais, 100% das recomendações finais foram academicamente válidas: pré-requisitos satisfeitos, orçamento

de dificuldade respeitado e zero conflitos de horário. O pipeline completo executa em menos de 1 segundo em CPU após o carregamento inicial do modelo SBERT (aproximadamente 5 segundos, 500 MB de RAM). A Tabela 4 resume os resultados qualitativos.

Table 4: Resultados por cenário simulado

Cenário	Interesse	Disc. recomendadas	Conflitos
Calouro (1º período)	“Gosto de exatas”	5	0
Meio de curso (foco IA)	“Inteligência artificial e dados”	5	0
Optativa livre	“Empreendedorismo e gestão”	5	0
Disciplina complementar	“Automação industrial”	5	0
Reta final	“Engenharia de software”	5	0
Generalista	“Qualquer área de engenharia”	5	0

7 Discussão

7.1 Análise do classificador BERT

A discrepância entre acurácia (89%) e F1 (0,00) do BERT fine-tuned é explicada pelo desbalanceamento severo dos dados: 94% dos exemplos são negativos. Um classificador trivial que prevê “não relevante” para todas as entradas atinge 94% de acurácia — o BERT está essencialmente colapsando para esta estratégia. A correção passa por técnicas de balanceamento como `pos_weight` no cálculo da loss (atribuindo peso maior aos exemplos positivos) ou `WeightedRandomSampler` no `DataLoader`. Esta é uma limitação conhecida, com correção prevista para a próxima iteração do projeto.

7.2 Análise da arquitetura híbrida

O principal resultado deste trabalho é a demonstração empírica de que a arquitetura híbrida — semântica + regras — é não apenas desejável, mas necessária para o domínio de recomendação acadêmica. O SBERT isolado é insuficiente (Precision@10 de 2,86%) pois desconhece a estrutura curricular; os filtros são corretos mas não capturam interesses pessoais. A combinação dos dois produz recomendações semanticamente relevantes e academicamente viáveis.

O fine-tuning progressivo em três estágios demonstrou ser uma estratégia adequada para datasets pequenos, evitando overfitting ao descongelar o modelo gradualmente. Contudo, o desbalanceamento de classes dominou o comportamento do classificador, indicando que a qualidade dos dados (balanceamento e representatividade) é tão importante quanto a arquitetura do modelo.

7.3 Limitações identificadas

Três limitações principais foram identificadas:

1. **Ementas genéricas:** 32% das disciplinas possuem ementas inferidas (ex.: “Disciplina de Introdução à Robótica”), textualmente similares entre si, reduzindo a discriminação semântica dentro de uma mesma área.
2. **Dependência de dados estáticos:** a base reflete a oferta de 2026/1. Horários e ementas mudam a cada semestre, exigindo re-coleta manual.
3. **Avaliação exclusivamente sintética:** todos os labels são gerados por regras determinísticas. Sem dados reais de preferência de alunos, não é possível medir a qualidade da recomendação do ponto de vista do usuário final.

8 Interface de Demonstração

Como demonstração interativa do sistema, foi desenvolvida uma aplicação web com Streamlit. A interface permite que o usuário: (1) selecione as disciplinas já concluídas; (2) descreva seus interesses em linguagem natural (ex.: “Gosto de inteligência artificial e análise de dados”); e (3) ajuste o orçamento de dificuldade e a quantidade de disciplinas desejadas. Ao clicar em “Recomendar”, o sistema executa o pipeline completo e exibe uma tabela com as disciplinas sugeridas (código, nome, score de similaridade, dificuldade, horários e pré-requisitos), além de alertas sobre conflitos e pré-requisitos não atendidos.

== Recomendador de Disciplinas - GEES UFMG ==		
Perfil: “Gosto de IA e dados”		
#1 EPB038	- Aprendizado de Máquina	Score: 0.83
#2 DCC204	- Algoritmos e Estruturas de Dados III	Score: 0.79
#3 ELE085	- Controle Digital	Score: 0.71
#4 EPD108	- Pesquisa Operacional I	Score: 0.68
#5 ELE031	- Eletrônica Analógica	Score: 0.65
Orçamento de dificuldade: 15.6 / 22 0 conflitos de horário		

Figure 1: Exemplo da interface Streamlit com recomendação para perfil com interesse em IA.

9 Conclusão

Este trabalho apresentou um sistema de recomendação de disciplinas para o curso de Engenharia de Sistemas da UFMG, integrando busca semântica com Sentence-BERT (BERTimbau), classificador BERT com fine-tuning progressivo e filtros estruturais determinísticos. A principal contribuição é a demonstração de que a arquitetura híbrida é essencial para o domínio: o SBERT captura a dimensão subjetiva dos interesses do aluno, enquanto as regras de pré-requisitos, balanceamento de dificuldade e prevenção de conflitos conferem rigor acadêmico às recomendações.

Os resultados quantitativos evidenciam que a busca semântica isolada é insuficiente (Precision@10 de 2,86%, MRR de 0,076), mas os filtros estruturais elevam a qualidade final a 100% de aderência ao PPC. O fine-tuning progressivo em três estágios mostrou-se adequado, porém o desbalanceamento de classes (94% negativos) comprometeu o F1 do classificador BERT — limitação a ser corrigida com técnicas de re-ponderação da loss.

Como trabalhos futuros, destacam-se:

1. Coleta de dados reais de preferência de alunos via questionário, substituindo labels determinísticos por avaliações de relevância;
2. Fine-tuning do SBERT com CosineSimilarityLoss sobre pares (perfil, disciplina), especializando os embeddings no domínio acadêmico;
3. Integração com a API do SIGA UFMG para atualização automática de horários e pré-requisitos a cada semestre;
4. Avaliação com usuários reais para medir satisfação e taxa de adoção das recomendações.

References

- [1] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT 2019*.
- [2] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of EMNLP-IJCNLP 2019*.
- [3] Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. *Proceedings of BRACIS 2020*.
- [4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Proceedings of NeurIPS 2017*.
- [5] Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., Drame, M., Lhoest, Q., & Rush, A. M. (2020). Transformers: State-of-the-Art Natural Language Processing. *Proceedings of EMNLP 2020: System Demonstrations*.
- [6] GEES UFMG. Grade Curricular — Engenharia de Sistemas. <https://geesufmg.com/curso/grade-curricular>. Acesso em: jun. 2026.
- [7] UFMG. Estrutura Curricular — Engenharia de Sistemas (2023/1). https://virtual.ufmg.br/plataforma/pluginfile.php/656374/mod_resource/content/4/ES.pdf. Acesso em: jun. 2026.
- [8] Colegiado de Engenharia de Sistemas. Grade Horária 2026/1. https://drive.google.com/file/d/1ewsZBL07xIb_FlQXn_5I3Z-Gn4Nya1Ab/view. Acesso em: jun. 2026.
- [9] Colegiado de Engenharia de Sistemas. Documentação do Projeto Pedagógico do Curso. <https://drive.google.com/drive/folders/1v-z55BIy1l1Z80KB1gPGVy0zqD8HEsD5>. Acesso em: jun. 2026.