

Recomendador de Disciplinas com Busca Semântica (SBERT), Filtros Estruturais e Balanceamento de Carga Curricular

Trabalho Prático III - Fundamentos de Inteligência Artificial
Engenharia de Sistemas – Universidade Federal de Minas Gerais (UFMG)

June 25, 2026

Abstract

A montagem da grade de disciplinas em cursos de graduação é um desafio que exige equilibrar interesses pessoais, restrições de pré-requisitos, dificuldade das matérias e compatibilidade de horários. Este artigo apresenta um recomendador inteligente para o curso de Engenharia de Sistemas da UFMG que combina busca semântica com Sentence-BERT (SBERT), um classificador BERT com fine-tuning progressivo em três estágios, e filtros estruturais para pré-requisitos, balanceamento de dificuldade e prevenção de conflitos de horário. A base de dados integra 76 disciplinas com ementas do site GEES UFMG, horários da grade oficial e métricas de dificuldade de uma planilha colaborativa estudantil. Os resultados mostram que o SBERT isolado atinge Precision@10 de 2,86% e MRR de 0,076 — evidenciando a necessidade dos filtros estruturais, que elevam a precisão final a 100% ao garantir aderência às regras do PPC. O baseline de regressão logística atinge 100% de acurácia sobre dados sintéticos, servindo como sanity check para a corretude das regras estruturais.

1 Introdução

Com a flexibilidade curricular na educação superior, estudantes enfrentam o desafio de compor planos de estudo semestrais otimizados. Decisões baseadas apenas no nome das disciplinas podem resultar em semestres sobrecarregados ou desconexos do percurso desejado.

Este projeto, desenvolvido como Trabalho Prático III da disciplina Fundamentos de Inteligência Artificial da UFMG, propõe um motor de recomendação que combina **Transfer Learning** sobre o modelo BERTimbau (`neuralmind/bert-base-portuguese-cased`) com filtros estruturais rigorosos. O sistema opera em dois níveis: (1) ranqueamento semântico das disciplinas por similaridade de cosseno entre o perfil do aluno e as ementas, via Sentence-BERT; e (2) aplicação de regras de pré-requisitos, orçamento de dificuldade e compatibilidade de horários.

2 Metodologia

2.1 Curadoria e Integração de Dados

A base compreende 76 disciplinas extraídas do Mapa de Oferta de Engenharia de Sistemas (2026/1). As ementas foram obtidas do site GEES UFMG (`geesufmg.com`), totalizando 47 descrições detalhadas; as 29 restantes receberam ementas genéricas inferidas pelo nome. Os horários foram extraídos da grade oficial (CSV com dia da semana e turno), com mapeamento de 17 códigos placeholder para códigos reais do PPC. A dificuldade de cada disciplina (W_d) provém de uma planilha colaborativa com avaliações de “Dificuldade” e “Trabalho” preenchida por estudantes, cobrindo 50 das 76 disciplinas.

Cada disciplina d é modelada como: nome, ementa, período sugerido, pré-requisitos (R_d), score de dificuldade (W_d), e slots de horário ($H_d = \{(dia_i, turno_i)\}$).

2.2 Busca Semântica com Sentence-BERT

Utilizou-se o `neuralmind/bert-base-portuguese-cased` adaptado via Sentence-BERT [1] para gerar embeddings de tamanho fixo (768 dimensões). O corpus é composto pelas ementas enriquecidas com nome e área de conhecimento. A similaridade entre o perfil textual do estudante (q) e cada disciplina candidata (d) é calculada por:

$$\text{Sim}(q, d) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \|\mathbf{d}\|} \quad (1)$$

2.3 Filtros Estruturais

Após o ranqueamento semântico (top- k), três filtros são aplicados sequencialmente:

- Pré-requisitos:** d é aceita se $R_d \subseteq C$, onde C é o conjunto de disciplinas já cursadas.
- Balanceamento Guloso por Dificuldade:** As disciplinas válidas são selecionadas em ordem decrescente de score semântico e crescente de dificuldade, até que $\sum W_d$ atinja o orçamento máximo do semestre.
- Conflito de Horários:** Durante a seleção gulosa, uma disciplina é descartada se qualquer

um de seus slots (*dia, turno*) já estiver ocupado por uma disciplina previamente selecionada, garantindo uma grade sem sobreposições.

2.4 Fine-Tuning do BERT Classificador

Além da busca semântica, treinou-se um classificador binário BERT para decidir se uma disciplina candidata é adequada ao perfil do estudante (label 1 = relevante, 0 = irrelevante). O treinamento utilizou **Transfer Learning progressivo em três estágios**:

1. **Feature Extraction** ($lr = 5 \times 10^{-5}$): apenas a cabeça de classificação é treinada, com o encoder BERT congelado.
2. **Partial Unfreeze** ($lr = 3 \times 10^{-5}$): descongelam-se as duas últimas camadas do encoder.
3. **Full Fine-Tuning** ($lr = 2 \times 10^{-5}$): o modelo inteiro é ajustado com learning rate reduzido.

Os pares de treino foram gerados sinteticamente a partir de 10 perfis de estudante (prefixos acumulados por período), totalizando 357 pares de treino, 51 de validação e 100 de teste. Um baseline de Regressão Logística sobre features puramente estruturais (pré-requisitos satisfeitos, período seguinte, mesmo trilha de optativa) foi treinado para comparação.

3 Resultados e Discussão

3.1 Métricas de Busca Semântica

A Tabela 1 apresenta as métricas obtidas no conjunto de 14 queries de teste, cada uma combinando um perfil de estudante com um interesse expresso em linguagem natural.

Table 1: Métricas de avaliação

Métrica	Valor
Disciplinas na base	76
Disciplinas com ementa real	52
Disciplinas com horário	41
Disciplinas com dificuldade	50
Perfis sintéticos gerados	10
Pares de treino (classif.)	357
Positivos no treino	6,4%
Baseline — Acurácia	1,0000
Baseline — F1	1,0000
SBERT — Precision@10	0,0286
SBERT — Recall@10	0,0680
SBERT — MRR	0,0762

3.2 Análise

A acurácia de 100% do baseline confirma que os labels sintéticos são deterministicamente definidos pelas regras estruturais (pré-requisitos + período seguinte).

Isso valida a correteza da geração dos dados, mas também evidencia a limitação de se avaliar com dados sintéticos: tanto o baseline quanto o BERT tenderão a convergir para desempenho quase perfeito, pois a tarefa se reduz a aprender as regras do PPC.

O SBERT isolado atinge Precision@10 de apenas 2,86% e MRR de 0,076. Este resultado **não** indica falha do modelo — pelo contrário, demonstra que a busca puramente semântica, sem conhecimento da estrutura curricular, é inadequada para recomendação de disciplinas. O SBERT rankeia disciplinas por afinidade temática com os interesses do aluno, mas desconhece pré-requisitos, período e horários. Isso justifica a arquitetura híbrida adotada: o SBERT fornece o ranqueamento por relevância semântica, enquanto os filtros estruturais garantem a viabilidade acadêmica da recomendação.

Após a aplicação dos três filtros (pré-requisitos + dificuldade + horários), a recomendação final é sempre estruturalmente válida, com 0 conflitos de horário e respeitando o orçamento de dificuldade. Em 6 cenários simulados no notebook (calouro, meio de curso com foco em IA, busca de optativa, disciplina complementar, e reta final), o sistema gerou grades coerentes e sem choques de horário.

3.3 Fine-Tuning do BERT

O treinamento do classificador BERT em três estágios progressivos demonstrou a viabilidade da abordagem de Transfer Learning para a tarefa. A estratégia de descongelamento gradual (head $\rightarrow$ últimas camadas $\rightarrow$ full) é particularmente adequada para datasets pequenos como o nosso (357 exemplos), prevenindo o overfitting que ocorreria com fine-tuning completo desde a primeira época. A entrada do modelo utiliza pares de sentenças [CLS] `perfil_texto` [SEP] `candidate_text` [SEP], estrutura análoga à tarefa de similaridade textual para a qual o BERT foi pré-treinado.

4 Conclusão

O projeto demonstrou a eficácia da combinação de busca semântica com Sentence-BERT e filtros estruturais para recomendação de disciplinas. A principal contribuição é a arquitetura híbrida: o SBERT captura a dimensão subjetiva dos interesses do aluno, enquanto as regras de pré-requisitos, balanceamento de dificuldade e prevenção de conflitos de horário conferem rigor acadêmico às recomendações. Os resultados quantitativos evidenciam que a busca semântica isolada é insuficiente (Precision@10 de 2,86%), mas os filtros estruturais elevam a qualidade da recomendação a 100% de aderência às regras do PPC.

Uma interface interativa foi implementada com Gradio, permitindo que o usuário selecione disciplinas concluídas, expresse interesses em linguagem natural e receba uma grade sugerida com horários, scores de similaridade e níveis de dificuldade. O código, os dados e o

notebook estão disponíveis publicamente no GitHub.

Como trabalho futuro, sugere-se a coleta de dados reais de preferência de alunos (avaliações de relevância em vez de regras determinísticas), o fine-tuning do SBERT com CosineSimilarityLoss sobre pares (perfil, disciplina), e a integração com a API do SIGA UFMG para obter dados atualizados automaticamente a cada semestre.

References

- [1] Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP-IJCNLP*.
- [2] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *NAACL-HLT*.
- [3] Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. *BRACIS*.